

식물 단면 현미경 영상을 이용한 인공지능 기반 토양 산성도 분류

박혜인¹⁺, 권은지²⁺, 김윤서²⁺, 박소율²⁺, 김호영^{2*}, 조환호^{1*}¹건양대학교 의료인공지능학과, ²중일고등학교

AI-based soil acidity classification using plant cross-section microscopic images

Hyein Park¹⁺, Eunji Kwon²⁺, Yoonseo Kim²⁺, Soyul Park²⁺, Hoyung Kim^{2*}, Hwan-ho Cho^{1*}¹Department of Medical Artificial Intelligence, Konyang University²Jung-il High School

* corresponding authors

+ These authors contributed equally to this work.

Abstract Soil acidity affects the habitat of plants and microorganisms, causing fatal environmental problems. Recent advances in artificial intelligence have led to rapid innovation across various fields, including industry, medicine, and the environmental science. In this study, we examined the feasibility of an AI-based approach to classify soil acidity using microscopic images of plants grown in soils with different pH concentrations.

• Key Words: Environmental science, Deep learning, Soil acidity, Plant, Microscopic image, Classification

I. Introduction

토양의 산성화는 식물과 미생물의 서식 환경에 영향을 미치며, 심각한 환경 문제를 유발한다 [1]. 국내 토양의 산성도는 2010년부터 10년간 pH 5.14에서 pH 4.3으로 약 15% 감소하며 빠른 산성화가 진행 중이다 [2]. 이에 토양환경보전법에서는 특정 토양 오염 관리대상 설치자에게 주변 토양오염검사를 의무화하고 있다 [3]. 하지만, 토양오염검사의 과정이 매우 복잡하고, 검사비용이 발생하는 등의 한계점이 존재한다.

인공지능은 hand-crafted feature를 사용하는 기계학습과 인공 신경망에 back-propagation 적용하는 딥러닝 방식을 아우르는 용어이다 [4]. 최근 인공지능 알고리즘의 발전으로 인해, 의료, 산업, 환경과학 등 사회 전반 분야가 빠르게 변화하고 있다 [5]. 특히 인공지능은 시간당 처리 효율이 매우 높아, 토양검사 소요시간 및 경제적 제약을 해결할 수 있다.

본 연구에서는 오염된 토양에서 배양한 식물의 단면 현미경 영상을 이용하여 딥러닝 모델이 토양의 산성도를 분류할 수 있는지 실험하였다. 세 단계 산성도의 토양에서 3가지 식물을 배양하였고, 각 식물의 단면 현미경 영상을 이용해 딥러닝 모델을 훈련하고 성능을 평가하였다.

II. Methods

2.1 식물의 선정 및 배양

실험에는 비늘줄기를 가진 백합, 양파와 정화식물 스투키를 사용하였다. 비늘줄기는 식물의 뿌리와 같이 땅속에

서 성장하며 양분을 저장하므로, 토양의 산성도 분류에 효과적으로 사용될 수 있고 [6], 정화식물은 유해물질을 거르는 특성이 있어 토양의 산성도 분류에 효과적일 수 있다.

토양의 산성도는 일반 토양 8kg당 pH 3, 4, 7 용액을 각각 100mL씩 혼합하여 3단계로 조절하고, 산성도별로 3개씩 총 9개의 화분을 만들었다. 각 화분에는 같은 식물을 3개씩 심어 2주간 성장한 후 현미경 영상 촬영에 사용하였다 (Figure 1).



Figure 1. Cultivation setting

2.2 표본 샘플 제작 및 현미경 영상 데이터 수집

백합은 전체 줄기를 10등분 하여 10개의 샘플을 추출한 후, 각 샘플의 윗부분과 중간 부분의 슬라이스로 표본을 제작하였다. 스투키는 각 개체에서 가장 길고 두꺼운 줄기 5개를 선택한 후 앞을 10등분 하여 10개의 샘플을 추출하였고, 각 샘플의 위와 중간 부분의 슬라이스를 표본으로 제작하였다. 양파는 뿌리 제거 후 세로로 10등분하여 한 층을 하나의 샘플로 지정하였고, 표피층 제거 후 유세포 층을 관찰하였다.

현미경 영상 데이터 수집은 식물 화상기를 부착한 현미경으로 수행하였고, 600(40x15)배율을 사용하여 한 샘플당 2개의 표본을 각각 약 15장씩 촬영하였다. 표본을 조금씩 움직여 다양한 부분을 촬영하였고, 한 화분에 배양된 3개체 중 2개체

의 현미경 영상은 인공지능 모델 훈련용, 1개체의 영상은 테스트용으로 사용하였다. OSUN 2.0 프로그램을 이용해 영상을 캡처하였으며 (Figure 2), 수집된 데이터의 수량은 Table 1과 같다.




Figure 2. Representative image of lily, onion, stuckyi

Table 1. Amount of collected images

		pH 3 혼합	pH 4 혼합	pH 7 혼합
백합	Training	616	643	634
	Test	309	317	322
양파	Training	600	595	601
	Test	300	300	300
스투키	Training	600	614	609
	Test	299	305	310

2.3 딥러닝 모델 훈련

모델링을 위해 ImageNet으로 사전 훈련된 MobileNetV2가 backbone으로 사용되었다 [7]. 영상은 모델에 입력되기 전에 224x224 크기로 조정하였고, MobileNetV2의 전처리 과정을 거쳤다. 이후 모델 최적화를 위해 training data를 7:3 비율로 나누어 training, validation set으로 분할하였다.

MobileNetV2의 top layer를 제거한 후 global average pooling과 각각 100개, 50개의 노드를 갖는 2개의 Fully Connected (FC) layer (ReLU activation) 및 3개의 노드를 갖는 FC layer (Softmax activation)을 추가하였다. 최적화에 Categorical cross entropy loss를 사용하였고, Adam optimizer (learning rate 1e-4)를 이용하여 50 epoch를 훈련하였다. 훈련 중에 MobileNetV2의 가중치는 고정되었고, 최적 모델은 validation loss의 최솟값을 기준으로 선택하였다.

III. Results

백합, 양파, 스투키 모델은 각각 27, 23, 23 epoch에서 최적의 loss를 보였다. Table 2는 최적의 epoch에서 각 모델의 성능을 보여준다. 세 가지 식물 중 백합의 영상이 토양 산성 정도를 구분하는 데에 가장 높은 성능을 보였다. Figure 3, 4는 test 성능이 가장 높은 백합 모델의 training curve와 confusion matrix를 나타낸다.

Table 2. Performance of each model

	백합	양파	스투키
Training	0.9927	0.9395	0.9308
Validation	0.8333	0.7382	0.7005
Test	0.7268	0.4455	0.5470




Figure 3. Loss and accuracy curve of lily model




Figure 4. Confusion matrix of lily model

IV. Conclusion

본 연구에서는 식물 단면의 현미경 영상을 사용하여 세 단계의 산성도를 딥러닝으로 분류 가능한지 확인하였다. 성능 평가 결과, 백합을 사용한 분류 성능이 test data에서 0.7268로 가장 높았고, confusion matrix에서는 pH3과 pH4를 혼합한 토양을 서로 잘못 분류하는 경향이 나타났다. 본 연구 결과는 토양의 정확한 pH농도를 측정하지 않은 점에 한계가 있으며, 추후 보강된 연구를 통해 신속한 토양검사 기법 개발과 비용 절감에 기여할 수 있을 것이다.

ACKNOWLEDGMENTS

본 논문은 대전시 교육청 Research & Education (R&E) 사업의 지원을 받아 수행된 것임.

REFERENCES

- [1] Robson, A. D., and L. K. Abbott. "The effect of soil acidity on microbial activity in soils." Soil acidity and plant growth (1989): 139-165.
- [2] 구남인, 이아림, 차상섭, "2019 전국 산림토양 산성화 현황", 국립산림과학원, 서울, 2020
- [3] 토양환경보전법 제 13조, 토양오염검사
- [4] LeCun, Yann, Yoshua Bengio, and Geoffrey Hinton. "Deep learning." nature 521.7553 (2015): 436-444.
- [5] Zhong, Shifa, et al. "Machine learning: new ideas and tools in environmental science and engineering." Environmental Science & Technology 55.19 (2021): 12741-12754.
- [6] Bell, Adrian D., and Alan Bryan. "Plant form: an illustrated guide to flowering plant morphology.", Timber Press, 2008.
- [7] Sandler, Mark, et al. "Mobilenetv2: Inverted residuals and linear bottlenecks." Proceedings of the IEEE conference on computer vision and pattern recognition. 2018.